

# Кирилл Зинченко

ML / LLM-ИНЖЕНЕР · МУЛЬТИАГЕНТНЫЕ СИСТЕМЫ · RETRIEVAL · ПРОДАКШН ML

kirillzinchenko2006@gmail.com · +7 938 116-78-40 · Telegram @MOJEMI · github.com/Norsaje

Ростов-на-Дону · релокация и удалённая работа

ML/LLM-инженер. Весь цикл: дообучение, retrieval, оркестрация агентов, продакшн-инференс, MLOps, аудит.

## ДОСТИЖЕНИЯ

Top-40, Yandex Cup (Аналитика) · Top-50, Yandex ML Challenge · Призёр BlackBox Hackathon (состязательное тестирования собственного harness LLM) · Победитель «Я - профессионал» программирование · Финалист Young Con 2025 · AIDAO

## ОПЫТ РАБОТЫ

**Сбер** · Эксперт по цифровым технологиям аудита

Март 2026 – наст. время

- Дообучил и перестроил агента CheetahClaws под внутреннюю инфраструктуру Сбера, вывел в прод. Другие команды используют его для оркестрации CV- и NLP-задач.
- Спроектировал иерархическую архитектуру агентов: управляющий агент разбирает запрос, распределяет подзадачи по специализированным агентам и проверяет каждый уровень перед агрегацией.
- Собрал слой инструментов агентов: семантический поиск по внутренним данным, изолированное исполнение, адаптеры к внутренним системам, выбор инструмента по контексту задачи в цикле с самокоррекцией.
- Вынес память агентов за пределы контекстного окна через retrieval, сжатие контекста и ранжирование.
- Сделал прогоны воспроизводимыми и пригодными для аудита: трассировка связывает запрос с вызовами инструментов и артефактом, вход и выход валидируются на границах агентов, доступы по Zero Trust IAM.
- Настроил оценку прогонов: успешность планирования, корректность артефакта, стоимость задачи. Сравнивал на них стратегии оркестрации.
- Сейчас занимаюсь R&D предобучения моделей для задач аудита.

**Exine** · ML-инженер, проектная работа, 3 месяца

2025

- Вывел в прод два сервиса: LLM-пайплайн, приводящий шумные записи из PostgreSQL к нормализованной JSON-схеме, и роутер, выбирающий модель и провайдера по домену, длине контекста, стоимости, SLA.
- Закрыв проблему невалидного вывода на границе API: дообучение LoRA/QLoRA под домен, few-shot шаблоны, ограниченная генерация по JSON Schema, жёсткая валидация, идиоматичные джобы.
- Снизил задержку и стоимость: кэширование эмбедингов и токенизации, асинхронный FastAPI, горячие пути парсинга переписаны на C++.
- Мерил экстракцию по совпадению со схемой и F1 по полям, retrieval по faithfulness и groundedness, роутинг проверял A/B-тестами против стоимости запроса.

**Eco Scan** · Data Scientist / ML-инженер, компьютерное зрение для городских администраций

Июнь 2024 – июнь 2025

- Отвечал за ML-часть продукта, который находит дефекты городской инфраструктуры на изображениях: от инструкций для разметки и пайплайнов данных до инференса, мониторинга и пилотов с городами.
- Обучал модели детекции и сегментации на PyTorch с transfer learning по precision/recall, mAP и IoU, настраивал устойчивость к реальным условиям съёмки, а не к чистым кадрам.
- Поднял инференс на FastAPI в Docker и Kubernetes, интегрировал с бэнкэндом и ГИС-слоем (PostGIS, Kafka, Redis): CI/CD моделей, версионирование в MLflow и DVC, мониторинг дрейфа в Prometheus.

## ПРОЕКТЫ

- **Celerity** (C++). Мультимодальный поиск без обучения, компактный retrieval без внешних сервисов.
- **Secure\_chatbot** (Python). Чат-бот с модерацией контента, RAG, оркестрацией инструментов, аудитом действий, контролем доступа.

## ТЕХНИЧЕСКИЕ НАВЫКИ

|              |                                                                                                    |
|--------------|----------------------------------------------------------------------------------------------------|
| Языки        | Python, C++, SQL                                                                                   |
| LLM и агенты | LangChain, LangGraph, оркестрация агентов, RAG, LoRA/QLoRA, оценка LLM, MLSecOps                   |
| ML и CV      | PyTorch, Hugging Face Transformers, scikit-learn, OpenCV, XGBoost, детекция, сегментация, NLP      |
| Платформа    | FastAPI, Docker, Kubernetes, PostgreSQL/PostGIS, Redis, Kafka, MLflow, DVC, CI/CD, Prometheus, Git |

## ОБРАЗОВАНИЕ

РГЭУ (РИНХ) · бакалавриат, прикладная информатика

окончание 2028

Яндекс Образование. MLSecOps: безопасность LLM-приложений. StudCamp «Математика в ИИ» (СПбГУ), 2025  
StudCamp «Безопасный генеративный ИИ» (УрФУ)